

Analiziramo pre nego što modelujemo: EDA kao početni korak

Petak, 09:05 AM – Google Colab chat, #ml-projekat-reviews-v.2

Alex: Ljudi, dataset je „sleteo” – imamo skoro 170.000 recenzija. Mislim da je vreme da proverimo u kakvu smo avanturu upali!

Marc: Znači, vreme je za dobro staro „njuškanje po podacima”.

Joakim: Ja samo molim da ne bude praznih kolona kao prošli put... Da krenemo od head(), pa da posle ne bude iznenađenja!

Alex: E, ovog puta idemo ozbiljno – radimo EDA kao pravi tim! Pandas, Matplotlib, seaborn – sve što imamo, bacamo u igru.

Marc: I onaj stari describe() – bez njega ne počinjem nijedno jutro!

Nakon što smo postavili čvrste temelje – od organizacije projekta do cloud okruženja i preuzimanja velikog skupa podataka sa recenzijama – pre nego što bilo šta modelujemo, neophodno je da razumemo kakve podatke imamo, u kakvom su stanju i u kakvom međusobnom odnosu.

Upravo to je cilj istraživačke analize podataka (EDA – exploratory data analysis).

Zašto je EDA važna?

Zato što bez pravog razumevanja podataka nijedan model, ma koliko bio sofisticiran, ne može pogoditi metu. To je trenutak kada podatke prestajemo da gledamo samo kao tabele i počinjemo da uočavamo obrasce, izuzetke i potencijalne probleme.

Šta ćemo proći u ovoj lekciji?

- Proverićemo da li postoje nedostajuće ili nekonzistentne vrednosti.
- Analiziraćemo raspodelu sentimenta i drugih ključnih karakteristika.
- Pogledaćemo da li postoje šabloni koji bi mogli pomoći u klasifikaciji.
- Vizualizovaćemo sve važno – koristeći pandas, Matplotlib i seaborn, baš kao u prethodnim kursevima, ali sada na pravom big data

Naš cilj? Da osetimo podatke i otkrijemo sve što može da nam pomogne u sledećim fazama – pre nego što uopšte krenemo u građenje modela.

Pripremi se da zaroniš u podatke, pronadeš skrivene priče i postaviš čvrste temelje za svaki sledeći korak. Prava analiza počinje sada!

Prvi susret s podacima – učitavanje iz oblaka

9:20 AM – Google Colab chat, #ml-projekat-reviews-v.2

Marc: OK, ekipo, vreme je za „prvi kontakt” sa našim velikim datasetom. Otvaram Colab, spremam URL – nema više skidanja fajlova lokalno!

Alex: Kako smo samo napredovali... Setite se kad smo u prvom kursu ručno unosili par redova u DataFrame. Sad vučemo 170.000+ redova direktno iz GitHuba!

Joakim: Dobro, samo da ne dobijem error zbog greške u linku, kao prošli put. Marc, copy-paste, molim te!

Marc: Ne brini, sve po PS-u.

Započinjemo analizu tako što učitavamo skup podataka direktno sa GitHuba i obavljam osnovni pregled njegovog sadržaja.

Evo koda koji koristimo:

```
1 import pandas as pd
2
3 # load dataset from GitHub
4 url = "https://raw.githubusercontent.com/vladimir-drešević/ml-product-reviews-project/main/data/product_reviews_full.csv"
5
6 df = pd.read_csv(url)
7
8 # Print shape (number of rows and columns)
9 print("Dataset shape (rows, columns):", df.shape)
10
11 # Show first 5 rows
12 print("\nFirst 5 rows:")
13 display(df.head())
14
15 # Show column data types and non-null counts
16 print("\nDataset info:")
17 df.info()
```

Napomena: Zameni YOUR_USERNAME i YOUR_REPOSITORY stvarnim nazivima svog GitHub naloga i repozitorijuma.

Alex: E, ovo je prava data science disciplina – ništa lokalno, sve online, sve u repozitorijumu, baš kako si nam pokazao u Colabu, Joakime!

Joakim: Samo da ovaj info() ne otkrije neki šok – tipa, prazne kolone ili čudne tipove podataka...

Šta je važno da proverimo u ovom koraku?

- Koliko redova i kolona dataset sadrži
- Kako izgledaju prvi zapisi
- Koje kolone postoje i koje tipove podataka imaju
- Da li su svi podaci pravilno učitani, bez grešaka

Ova faza je ključna za dijagnostiku podataka i osigurava da kasnije ne gubimo vreme na tehničke probleme.

Mini-aktivnost: Tvoj prvi susret sa podacima

Probaj da samostalno učitáš dataset koristeći svoj repozitorijum i Colab.

Zapiši u par rečenica:

- Koliko ima redova/kolona?
- Da li svi podaci deluju logično na prvi pogled?
- Ima li nešto neobično što si odmah primetio?

Pogledajmo zajedno kako ćemo učitati skup podataka i obaviti njegov osnovni pregled:

<https://www.youtube.com/watch?v=Hchk8SPGEQA>

Video: Učitavanje i osnovni pregled skupa podataka
Autor: ITAcademy

Provera nedostajućih vrednosti: Gde su nam rupe u podacima?

9:40 AM – Google Colab chat, #ml-projekat-reviews-v.2

Alex: Ljudi, pre nego što krenemo da „pržimo” modele, hajde da proverimo ima li rupa u podacima. Neću da mi model opet pukne na pola treninga!

Joakim: O, da... Setite se kad nam je prošli put 20% vrednosti u koloni bilo NaN, a mi jurili bag u kodu sat vremena.

Marc: E, to je data science karma: ako ne proveriš podatke – podaci te kazne!

Nakon što smo učitali i pregledali osnovne informacije o podacima, sledeći korak je da proverimo da li postoje nedostajuće vrednosti u nekoj od kolona.

1. Provera nedostajućih vrednosti po kolonama

```

1 # Count missing values per column
2 print("Missing values per column:")
3 print(df.isna().sum())

```

Marc: Ovo nam odmah kaže koliko je „rupa“ u svakoj koloni. Nekada je to samo par redova – a nekad baš ozbiljan problem.

2. Vizualizacija nedostajućih vrednosti


Joakim: Ajmo da bacimo i toplotnu mapu, da odmah vidimo gde škripi.

```

1 # Visualize missing data with seaborn heatmap
2 import seaborn as sns
3 import matplotlib.pyplot as plt
4
5 plt.figure(figsize=(10, 5))
6 sns.heatmap(df.isna(), cbar=False, cmap="YlOrRd")
7 plt.title("Missing Values Heatmap")
8 plt.show()

```

Pregledniji uvid u nedostajuće vrednosti može se dobiti korišćenjem vizualizacije. Evo šta dobijamo na ovaj način:



Prikaz nedostajućih vrednosti korišćenjem toplotne mape

Alex: Super je kad odmah vidimo da, recimo, sentiment ili title kolona „zjape“ na nekim mestima. Sad treba da odlučimo – čistimo, popunjavamo ili ignorišemo?

Zašto je ovo važno?

- Nedostajući podaci mogu totalno da zbune model i upropaste rezultate.
- Pravilna dijagnostika na startu štedi vreme kasnije.

Mini-aktivnost: Lovci na rupe

Pogledaj rezultate svoje toplotne mape i `.sum()` analize.

Odgovori u par rečenica:

- Koje kolone najviše pate od nedostajućih vrednosti?
- Da li su te kolone važne za model?
- Kako možeš da ih rešiš (brisanje/redovi, popunjavanje, ostaviš kako jeste)?

Pogledajmo zajedno kako da proverimo nedostajuće vrednosti koje postoje unutar našeg skupa podataka:

https://www.youtube.com/watch?v=PhSVKU_g8wM

Video: Provera nedostajućih vrednosti

Autor: ITAcademy

Koji je ton korisničkih recenzija? Prvi uvid u sentiment

10:51 AM – Google Colab chat, #ml-projekat-reviews-v.2

Joakim: OK, vreme je da zavirimo u glavnu zvezdu skupa podataka – kolonu sentiment. Ako ovde nešto nije u redu, cela naša analiza pada u vodu.

Marc: Sećate se Itanovih reči i balansa klasa? Nije isto trenirati model ako imamo 90% pozitivnih i 10% negativnih komentara. Hajde da proverimo situaciju!

Kolona sentiment predstavlja jednu od najvažnijih u ovom skupu podataka – ona sadrži ciljnu vrednost koju ćemo koristiti za klasifikaciju. U njoj se nalazi informacija o tome kakav je ton korisničkih recenzija.

U ovoj fazi analize:

- proverićemo koje vrednosti postoje u koloni sentiment;
- izbrojaćemo koliko recenzija postoji u svakoj klasi u ovoj koloni;
- vizualno ćemo prikazati raspodelu koristeći biblioteke Matplotlib i seaborn.

Ova analiza nam može pomoći da otkrijemo neravnotežu u klasama, što je važno znati pre treniranja bilo kog modela mašinskog učenja.

1. Numerički uvid u raspodelu sentimenta


```
1 # Count occurrences of each sentiment label
2 sentiment_counts = df['sentiment'].value_counts()
3
4 # Print counts
5 print("Sentiment distribution (counts):")
6 print(sentiment_counts)
7
```

Joakim: Ovako odmah znamo da li su klase „fer” ili će model morati da se bori sa neravnotežom.

2. Nakon ovoga, u analizu ćemo uključiti i vizualizaciju:

```
1 # Plot sentiment distribution
2 import seaborn as sns
3 import matplotlib.pyplot as plt
4
5 plt.figure(figsize=(6, 4))
6 plt.bar(sentiment_counts.index, sentiment_counts.values, color=['skyblue', 'salmon'])
7 plt.title("Sentiment Distribution")
8 plt.xlabel("Sentiment")
9 plt.ylabel("Number of Reviews")
10 plt.show()
```

Grafik koji se na ovaj način dobija izgleda ovako:



Uvid u sve vrednosti koje postoje unutar kolone sentiment

Alex: Kad vidimo ovakav grafikon, odmah možemo proceniti da li imamo problem sa balansom klasa. Ako je sve nagurano na jednu stranu – moramo to imati na umu kasnije, kad budemo procenjivali performanse modela!

Pogledajmo zajedno kako se obavlja analiza kolone sentiment i šta nam ona govori:

<https://www.youtube.com/watch?v=6ueAaFf3g28>

Video: Analiza kolone sentiment
Autor: ITAcademy

Mini-aktivnost: Šta se dešava sa cenama?

U našem skupu podataka postoji kolona `product_price` i već smo videli da njen tip nije numerički (`float` ili `int`), već tekstualni (`object`).

Istraži zašto je to tako i koje vrste vrednosti se pojavljuju u ovoj koloni. Zatim napiši kod za istraživačku analizu podataka kolone `product_price`.

Šta treba da uradiš?

1. Prikaži tip podatka kolone `product_price`.
2. Prikaži nekoliko prvih vrednosti.
3. Prikaži najčešće vrednosti.
4. Proveri da li unutar ove kolone ima nestrukturisanih tekstualnih zapisa poput `Free` ili `Not Available`?
5. Pronađi i prikaži sve različite nenumeričke vrednosti.

Pogledajmo rešenje.

```

1 # 1. Check the data type of the 'product_price' column
2 print("Data type of product_price column:", df['product_price'].dtype)
3
4 # 2. Display the first 10 values from the column
5 print("\nFirst 10 values in product_price column:")
6 print(df['product_price'].head(10))
7
8 # 3. Show the 20 most frequent values in the column
9 print("\nTop 20 most frequent values in product_price column:")
10 print(df['product_price'].value_counts().head(20))
11
12 # 4. Check for known non-numeric text values
13 problematic_values = ['Free', 'Not Available', 'N/A', 'None', '-', 'free', 'unknown', 'Unavailable']
14 # Identify rows containing these specific non-numeric values
15 mask_problematic = df['product_price'].astype(str).str.strip().isin(problematic_values)
16 df_problematic = df[mask_problematic]
17 print(f"\nFound {len(df_problematic)} rows with problematic textual values:")
18 display(df_problematic[['product_price']].drop_duplicates())
19
20 # 5. Find and display some of the non-numeric values
21 price_clean = df['product_price'].astype(str).str.strip()
22 price_numeric = pd.to_numeric(price_clean, errors='coerce')
23
24 invalid_prices = df[price_numeric.isna()]
25 print("Number of non-numeric prices:", len(invalid_prices))
26 display(invalid_prices[['product_price']].drop_duplicates().head(20))

```

Ukoliko naiđeš na poteškoće u realizaciji, možeš pogledati kompletan video-vodič sa koracima koje je potrebno sprovesti da bi se ona realizovala. Video-vodič pogledaj tek nakon što samostalno probaš da rešiš zadatak.

<https://www.youtube.com/watch?v=REesU8J2IGk>

Video: Analiza kolone sa cenama proizvoda

Autor: ITAcademy

Zaključak lekcije

Upravo smo završili jedan od najvažnijih koraka svakog ozbiljnog projekta mašinskog učenja – istraživačku analizu podataka (EDA). Umesto da jurimo što brže do modela, zaustavili smo se da upoznamo podatke, pronađemo probleme i osmislimo strategiju rada.

Šta smo postigli u ovoj lekciji?

- Proverili smo integritet podataka i pronašli nedostajuće vrednosti, čime smo izbegli moguće nevidljive greške kasnije u radu.
- Analizirali smo raspodelu klasa u koloni `sentiment` i uočili da li postoji balans, što je ključni preduslov za fer procenu modela.
- Dobro smo se upoznali sa vrstama i formatima podataka – otkrili smo gde su numeričke vrednosti, gde tip podatka škripi i kako to utiče na dalju analizu.
- Prvi put smo se poigrali vizualizacijama, koje su nam dale brzu i jasnu sliku o tome šta se u podacima zaista dešava.

- Vežbali smo timsku analizu, dijalog i proaktivno otkrivanje problema, baš kao u pravom data science okruženju.

Takeaways

- EDA je temelj – bez dobre analize nema pouzdane automatizacije!
- Svaka sumnjiva vrednost ili nejasan format podatka danas, može postati skupa greška sutra.
- Razumevanje raspodele i kvaliteta podataka pomaže nam da napravimo bolje modele, ali i da izbegnemo pogrešne zaključke.

Zapamti: Pravi data scientist nikada ne preskače EDA – to je naš radar za probleme i izvor svih dobrih rešenja.

Sledeći korak: Čišćenje i pretprocesiranje podataka

Sada kada znamo sa kakvim podacima radimo, vreme je za pravo prolećno čišćenje! U narednoj lekciji, zavrćemo rukave: uklanjamo višak, sređujemo nered, standardizujemo i pripremamo podatke tako da naš budući model može da zablista punim sjajem. Kvalitetan model počinje kvalitetnim podacima – idemo korak bliže profesionalnom ML rešenju!

Spremi se, sledeći korak pravi ključnu razliku između prosečnog i odličnog projekta!