

Inženjering karakteristika: Tamo gde podaci dobijaju smisao

Utorak, 02:17 PM – Google Colab chat, #ml-projekat-reviews-v.2

Joakim: OK, sada ulazimo u „magiju“ ML-a! Bacamo se na karakteristike – vreme je za ono što najviše voli svaki pravi data scientist.

Alex: Znači, biramo šta će naš model stvarno videti i koristi? Sad konačno možemo da izbacimo one čudne kolone koje ništa ne govore...

Marc: Ako još jednom nađem na prazan review_title koji je samo tačkica, šaljem ga u quarantine folder! Ali, šta mislite – ima li smisla uključiti i cenu proizvoda u model? Možda skuplje proizvode ljudi ocenjuju drugačije?

Joakim: Odlično pitanje! Hajde da isprobamo i to. Plus, pravimo novu kolonu – dužina recenzije. Dužina recenzija može na direktan način uticati na sentiment, odnosno obrnuto, sentiment može da odredi koliko će dugačke korisničke recenzije da budu.

Nakon što smo očistili i pripremili svoj skup podataka, vreme je da se pozabavimo jednim od ključnih koraka u svakom projektu mašinskog učenja – inženjeringom karakteristika (feature engineering).

Cilj ove faze je da iz postojećih podataka izdvojimo informacije koje su najrelevantnije za treniranje modela, ali i da pokušamo da generišemo nove, korisne karakteristike koje bi mogle poboljšati performanse modela.

Šta ćeš novo otkriti kroz ovu lekciju?

- Analiziramo sve postojeće kolone i biramo koje su zaista važne za naš model (klasifikacija sentimenta).
- Uklanjam kolone koje nemaju smisla za predviđanje (npr. ID-jevi, prazni naslovi...).
- Proveravamo da li cena proizvoda ima uticaj na ocenu – eksperiment i doza radoznalosti!
- Kreiramo potpuno novu karakteristiku: dužinu recenzije (broj karaktera/reči), jer svaka reč može biti presudna.

Ova faza pravi razliku između prosečnih i izuzetnih modela. Zato ćemo biti temeljni, kritični i kreativni – kao pravi ML tim.

Čišćenje tabele: Uklanjam nepotrebne kolone

02:29 PM – Google Colab chat, #ml-projekat-reviews-v.2

Alex: Pre nego što krenemo sa generisanjem novih karakteristika, hajde da malo počistimo svoju tabelu. Nema potrebe da model zna za svaki ID i naziv proizvoda – te informacije nam samo prave gužvu.

Marc: Prava Marie Kondo faza – ako kolona ne donosi radost modelu, izbacujemo je!

Joakim: Setite se onog trenutka u prošlom Colab kursu kad smo ostavili nepotreban index i sve grafike su bile haotične... Ovoga puta čistimo na vreme!

Zašto ovo radimo?

Cilj je da naš model bude fokusiran samo na informacije koje zaista mogu pomoći u predviđanju sentimenta recenzije. Zato ćemo zadržati samo one kolone koje su zaista relevantne za ovaj zadatak.

Koraci

1. Identifikujemo kolone koje nisu korisne za modelovanje.
Najlakše je da krenemo od onih kolona za koje znamo da nemaju nikakvu direktnu vezu sa tekstom recenzije i njenim sentimentom. Kolone poput:
 - review_uuid (ID svakog komentara – nije informativan) ili
 - product_name (naziv proizvoda – veoma širok i raznovrstan) nemaju realnu analitičku vrednost za našu klasifikaciju.Ove kolone možemo bezbedno ukloniti iz skupa podataka koji šaljemo na treniranje modela. Ako ih ostavimo, samo dodajemo šum modelu i komplikujemo kod.

2. Uklanjam ih iz našeg DataFramea:

```
1 # Drop columns that are not useful for modeling
2 df = df.drop(columns=['review_uuid', 'product_name'])
3
4 # Preview remaining columns
5 print("Remaining columns:")
6 print(df.columns.tolist())
```

3. Proveravamo da li je struktura tabele sada preglednija i jednostavnija za dalji rad.

Mini-izazov

Da li postoji još neka kolona koju bismo mogli da eliminišemo? Ako pronađeš nešto što ne donosi radost našem modelu, piši na EduWall – ko pronađe najviše nepotrebnih kolona, dobija kafu po izboru!

Pogledajmo zajedno kako se uklanjaju nepotrebne kolone iz našeg skupa podataka:

<https://www.youtube.com/watch?v=AzFZkSxzW98>

Video: Uklanjanje nepotrebnih kolona
Autor: ITAcademy

Da li zadržati kolonu product_price u modelu?

03:28 PM – Google Colab chat, #ml-projekat-reviews-v.2

Marc: Ljudi, imamo ključnu dilemu – da li product_price ima smisla za predviđanje sentimenta ili je samo šum u podacima? Hajde da proverimo vizualno!

Alex: E, ovo me podseća na onaj stari kurs sa Colabom, kad smo testirali slične sporedne karakteristike. Tada se ispostavilo da je bolje da ih izbacimo, ali nikad ne znaš dok ne pogledaš boxplot!

Pre nego što odlučimo da li ćemo zadržati kolonu product_price kao ulaznu karakteristiku za treniranje modela, postavljamo ključno pitanje:

Da li cena proizvoda ima ikakav uticaj na to da li je recenzija pozitivna, negativna ili neutralna?

Odgovor na ovo pitanje potražićemo tako što ćemo:

- analizirati raspon i raspodelu cena u skupu podataka;
- uporediti kako se cene raspoređuju po različitim sentiment klasama;
- vizualizovati podatke radi boljeg uvida.


Ako uočimo jasne razlike u cenama u odnosu na sentiment (npr. skuplji proizvodi imaju više negativnih recenzija), možda vredi zadržati ovu kolonu kao dodatnu karakteristiku. U suprotnom, možemo je slobodno ukloniti.

Analiza: Raspodela cena po sentimentu

Evo koda koji će nam pomoću u donošenju odluke:

```
1 import seaborn as sns
2 import matplotlib.pyplot as plt
3
4 # Show summary statistics grouped by sentiment
5 print("Price summary by sentiment:")
6 print(df.groupby('sentiment', observed=False)['product_price'].describe())
7
8 # Boxplot of prices by sentiment
9 plt.figure(figsize=(10, 5))
10 sns.boxplot(data=df, x='sentiment', y='product_price')
11 plt.title("Product Price Distribution by Sentiment")
12 plt.xlabel("Sentiment")
13 plt.ylabel("Product Price")
14 plt.grid(True)
15 plt.show()
```

Grafikon koji se dobija izgleda ovako:



Kutijasti dijagrami koji prikazuju raspodelu cena po sentimentu

Tumačenje grafikona

1. Raspodela cena je vrlo slična za sve tri sentiment klase.
 - Visina kutija (IQR) i položaj medijana gotovo su identični.
 - To znači da prosečne cene proizvoda kod kojih su korisnici ostavili pozitivnu, negativnu ili neutralnu recenziju – nisu značajno različite.
2. Postoje brojni ekstremi u sve tri grupe.
 - U svim slučajevima postoje proizvodi sa veoma visokom cenom (npr. 800, 1000, 1500 itd.).
 - Ovi ekstremni slučajevi nisu karakteristični ni za jedan sentiment.
3. Zaključak
 - Na osnovu ove vizualizacije, ne postoji jasan obrazac koji bi ukazivao na povezanost između cene proizvoda i tona recenzije.
 - Cena se ponaša nezavisno od sentimenta i verovatno nema značajan doprinos klasifikaciji.

Marc: Raspodele su „isti film” za sve klase. Očigledno je – cena ne utiče na ton recenzije!

Alex: Tako i meni deluje. Da je razlika bar malo očigledna... ali ovako, samo komplikujemo model.

Joakim: Super – jedan feature manje, jedan problem manje!

Preporuka: Možemo slobodno isključiti kolonu `product_price` iz skupa karakteristika koje šaljemo u model.

Pogledajmo zajedno kako da analiziramo efekat cena na konačni sentiment:

<https://www.youtube.com/watch?v=93VT-5LG0aY>

Video: Analiza uticaja cena na sentiment
 Autor: ITAcademy

Mini-izazov

Možeš li da zamisliš situaciju u kojoj bi cena bila važna? Da li za luksuzne proizvode ili određene kategorije korisnika možda postoji veza? Probaj samostalno – promeni boxplot po kategorijama proizvoda i uporedi!

Nova karakteristika: Dužina recenzije kao skriveni signal?

05:12 PM – Google Colab chat, #ml-projekat-reviews-v.2

Alex: Ljudi, palo mi je na pamet – da li duže recenzije znače veći bes ili veće oduševljenje? Da pokušamo da izračunamo prosečnu dužinu teksta po sentimentu?

Marc: E, to je baš fora koju smo radili i na prethodnom Python kursu – ali tada na malom uzorku, a sad imamo pravu „big datu“! Moguće da besne mušterije pišu epske eseje.

Joakim: Ili se možda najkraće recenzije pišu kad je sve bilo super („Top!“). Idemo na kod!

Izračunavanje dužine tekstualnog zapisa

Jedan od najjednostavnijih načina za kreiranje nove karakteristike iz teksta je da izračunamo dužinu svakog teksta. U našem slučaju, to znači izračunavanje koliko karaktera ima svaka recenzija (review_text).

Ova informacija može biti veoma korisna jer nam pomaže da otkrijemo skrivene obrasce u ponašanju korisnika.

Zašto je ovo važno?

- Korisnici koji pišu duže recenzije često su detaljniji – ponekad zato što žele da istaknu šta im se nije dopalo, pa se ovakvi slučajevi češće javljaju u negativnim komentarima.
- Kraće recenzije često prate pozitivno iskustvo – korisnici napišu Sve je super! ili Odlično! i nemaju potrebu da se detaljno raspišu.

Šta je sledeće što radimo?

- Dodajemo novu kolonu – U DataFrame unosimo kolonu review_length, sa brojem karaktera svake recenzije.
- Analiziramo osnovne statistike – Pogledamo prosečnu, minimalnu i maksimalnu dužinu recenzija.
- Poređenje po sentimentu – Ispitujemo da li se dužina recenzije razlikuje kod pozitivnih, negativnih i neutralnih recenzija.
- Vizualizacija – Pravimo boxplot koji jasno pokazuje razlike u dužini recenzija za svaku kategoriju sentimenta.

Ova jednostavna karakteristika (review_length) često donosi vredne informacije za modele mašinskog učenja, jer može pomoći modelu da lakše razlikuje tipove komentara – čak i bez dubinske analize samog teksta.


Analiza: Dužina tekstualnog zapisa

Evo koda kojim ćemo obaviti takvu analizu:

```

1 import seaborn as sns
2 import matplotlib.pyplot as plt
3
4 # Create new column with length of each review_text
5 df['review_length'] = df['review_text'].astype(str).str.len()
6
7 # Show basic stats
8 print("Review length summary:")
9 print(df['review_length'].describe())
10
11 # Group by sentiment and describe review length
12 print("Review length statistics by sentiment:")
13 print(df.groupby('sentiment', observed=False)['review_length'].describe())
14
15 # Visualize distribution of review length by sentiment
16 plt.figure(figsize=(10, 5))
17 sns.boxplot(data=df, x='sentiment', y='review_length')
18 plt.title("Review Length by Sentiment")
19 plt.xlabel("Sentiment")
20 plt.ylabel("Review Length (number of characters)")
21 plt.grid(True)
22 plt.show()
```

Vizualizacija koju na ovaj način dobijemo izgleda ovako:



Kutijasti dijagrami koji prikazuju raspodelu dužine recenzija za svaki sentiment

Tumačenje grafikona

1. Dužina recenzija je generalno slična bez obzira na sentiment.
 - Sva tri boksa (negative, neutral, positive) imaju sličan raspon dužine i slične srednje vrednosti (medijane).
 - To znači da nije izražena jaka veza između sentimenta i dužine recenzije.
2. Negativne recenzije imaju blago veći raspon.
 - Gornja ivica kutije (75. percentil) viša je, što pokazuje da su duže recenzije češće među negativnima. Takođe, među negativnim recenzijama ima više i onih ekstremno dugih.
 - Ovo može ukazivati na to da korisnici češće pišu duže komentare kada su nezadovoljni – možda detaljnije objašnjavaju zašto.
3. Svi sentimenti imaju dosta ekstremnih vrednosti.
 - Veoma duge recenzije (preko 400 karaktera) se javljaju u svim grupama, što je očekivano u velikim skupovima podataka.

Marc: Negativne recenzije stvarno imaju veću „kilometražu“, ali nije to baš ogromna razlika.

Alex: Super što imaš i ovde ekstremne vrednosti – očigledno neki korisnici vole da pišu romane, bez obzira na sentiment.

Joakim: I dalje bih ostavio ovu kolonu za model – ne smeta, a možda nekad i „preseče“ odluku!

Preporuka: Kolona `review_length` nije glavni pokazatelj sentimenta, ali kao pomoćna karakteristika, može doprineti tačnosti modela kada se kombinuje sa ostalim podacima – slobodno je možemo uključiti u model.

Šta smo naučili?

Svi sentimenti imaju dosta dugu rep distribuciju, ali negativne recenzije ipak prednjače u dužini – korisno, ali ne presudno!

Feature `review_length` je zanimljiv sporedni igrač – može malo pomoći, ali teško da će presuditi.

Mini-izazov: Smisli i nacrtaj dodatnu vizualizaciju!

Pokušaj da napraviš još neku vizualizaciju koja će nam pomoći u razumevanju uticaja koji dužina recenzije ima na njen sentiment.

Na primer:

- prikaži histogram dužina recenzija samo za pozitivne/negativne;
- isprobaj violin plot ili
- prikaz broja reči, ne karaktera.

Pogledajmo zajedno kako se kreira nova karakteristika koja pokazuje dužinu recenzija i koji je njen potencijalni uticaj na sentiment:

https://www.youtube.com/watch?v=_t1T0LORKZo

Video: Generisanje nove karakteristike (review_length) i analiza njenog uticaja na sentiment
Autor: ITAcademy

Zaključak lekcije

Došli smo do faze projekta gde podaci prestaju da budu samo sirov materijal, a počinju da postaju izvor poslovnog uvida i temelj inteligentnog modela. Inženjering karakteristika je upravo ta veza: selektovanjem, transformisanjem i kreiranjem novih osobina iz podataka, omogućavamo modelu da vidi ono što bi mu inače promaklo.

Šta smo postigli u ovoj lekciji?

- Selektovali smo ključne kolone: Zadržali smo samo one informacije koje zaista nose signal za predviđanje sentimenta.
- Doneli odluke na osnovu analize: Testirali smo ima li smisla koristiti kolonu sa cenom proizvoda i naučili kako podatak treba da zasluži mesto u modelu.
- Generisali nove karakteristike: Izračunali smo dužinu recenzije, dobili uvid u ponašanje korisnika i obogatili svoj skup podataka korisnom numeričkom informacijom.
- Naučili smo da svaki korak argumentujemo: Svaka karakteristika ima svoju priču – i znamo kako da tu priču ispričamo i kolegama i samom modelu!

Takeaways

- Pametan inženjering karakteristika često je ono što čini razliku između prosečnog i odličnog modela.
- Nije dovoljno imati mnogo podataka – važno je imati prave podatke.
- Analiza, refleksija i timska diskusija vode do kvalitetnijih odluka.

Ovim korakom smo ne samo očistili teren već i obezbedili svom modelu najbolji mogući poligon za učenje.

Sledeći korak: Odabir najboljeg algoritma za treniranje modela

Pripremili smo podatke i pažljivo izabrali karakteristike – sada dolazi trenutak kada mašina zaista preuzima stvar! U narednoj lekciji biramo algoritme, testiramo ih jedan protiv drugog i gledamo koji se najbolje snalazi u realnim uslovima. Da li će pobediti brzina, preciznost, otpornost na greške ili jednostavnost primene? Saznaćemo uskoro!

Spremi se, tvoj model uskoro ulazi u arenu!