

Introduction to Machine Learning

Regresija (kompletan ML workflow)

Vladimir Drešević

4/4

Od klasifikacije ka regresiji

- U prethodnim primerima model je birao kategoriju: pozitivno/negativno, spam/not spam, odobreno/odbijeno.
- Kod problema kao što je predviđanje vremena dostave, pitanje više nije: „Da li je dostava brza ili spora?”
- Novo pitanje glasi: „Koliko minuta će dostava trajati?”
- Kada očekujemo brojčanu vrednost, a ne klasu, ulazimo u oblast regresije.

Klasifikacija predviđa kategoriju, dok regresija predviđa broj.

Šta je regresija?

- Regresija je tip problema u mašinskom učenju u kome model pokušava da proceni numeričku vrednost.
- Rezultat regresionog modela može biti trajanje, cena, ocena, potrošnja, iznos ili neka druga količina.
- Primeri regresionih predikcija:
 - vreme dostave: 32 minuta
 - cena stana: 125000 evra
 - ocena proizvoda: 4.3
 - potrošnja energije: 87.3 kWh

Klasifikacija i regresija: isto učenje, drugačiji izlaz

- I klasifikacija i regresija uče iz prethodnih primera.
- U oba slučaja imamo ulazne podatke, ciljnu promenljivu, trening skup, test skup, model i evaluaciju.
- Razlika je u tipu odgovora:
 - klasifikacija: klasa ili oznaka
 - regresija: numerička vrednost
- Isti realni problem može se postaviti na dva načina:
 - „Da li će dostava trajati duže od 30 minuta?” → klasifikacija
 - „Koliko minuta će dostava trajati?” → regresija

Problem predviđanja vremena dostave

- Cilj modela je da proceni koliko će dostava trajati u minutima.
- Ciljna promenljiva je vreme dostave.
- Ulazne karakteristike mogu biti: udaljenost između restorana i korisnika, vremenski uslovi, gustina saobraćaja, tip vozila, stanje vozila, vreme preuzimanja porudžbine, vikend ili radni dan, broj dodatnih dostava.
- Model pokušava da nauči obrazac: ulazne karakteristike → vreme dostave.

Kompletan regresioni workflow

1. razumevanje problema
2. razumevanje podataka
3. EDA analiza
4. čiščenje podataka
5. inženjering karakteristika
6. Pretprocesiranje
7. treniranje modela
8. evaluacija
9. poređenje algoritama

Šta je EDA?

- EDA, odnosno istraživačka analiza podataka, predstavlja prvi sistematičan pregled novog skupa podataka.
- U ovoj fazi ne treniramo model i ne menjamo podatke, već je cilj da razumemo sa čime radimo.
- EDA odgovara na pitanja:
 - šta predstavlja jedan red?
 - koje kolone postoje?
 - koji su tipovi podataka?
 - da li postoje nedostajuće vrednosti?
 - da li postoje nelogične ili nevalidne vrednosti?
 - šta treba srediti pre modelovanja?

Šta proveravamo tokom EDA analize?

- **Osnovna struktura skupa podataka:** broj redova i kolona, nazivi kolona , tipovi podataka.
- **Kvalitet vrednosti:** nedostajuće vrednosti, tekstualne vrednosti sa razmacima, numeričke kolone učitane kao tekst, neujednačene kategorije.
- **Specifične provere za ovaj problem:** da li je ciljna kolona numerička, da li koordinate imaju smisla, da li su vremenske vrednosti validne.

Čišćenje podataka kao ponovljiv proces

- Čišćenje podataka pretvara sirove podatke u stabilnu osnovu za dalji rad.
- Umesto ručnog sređivanja, najbolje je napraviti skriptu sa funkcijama.
- Svaka funkcija rešava jedan konkretan problem.
- Funkcije se povezuju u pipeline koji se može pokrenuti svaki put nad novom verzijom podataka.
- Time čišćenje postaje deo projekta, a ne ručni ritual.

Tipični koraci pri čišćenju podataka

- Standardizacija naziva kolona:
 - pretvaranje naziva u snake_case
 - uklanjanje razmaka, zagrada i nepotrebnih znakova
- Uklanjanje viška razmaka iz tekstualnih vrednosti.
- Pretvaranje vrednosti poput "nan", "null", "None" i praznih stringova u prave nedostajuće vrednosti.
- Konverzija numeričkih kolona u odgovarajuće tipove.
- Provera ciljne promenljive.
- Sređivanje datuma, vremena i koordinata.

Šta je inženjering karakteristika?

- Cilj nije samo da podaci budu ispravni, već da informacije budu korisnije za model.
- Iz postojećih kolona pravimo nove karakteristike koje bolje opisuju problem.
- Primeri:
 - koordinate → udaljenost u kilometrima
 - vreme preuzimanja → sat, dan u nedelji, deo dana
 - vremenski uslovi → indikator lošeg vremena
- Na ovaj način model dobija jasnije signale za učenje.

Primeri korisnih karakteristika za vreme dostave

- **distance_km:**
 - udaljenost između restorana i lokacije isporuke
 - korisnija je od sirovih koordinata
- **pickup_hour:**
 - sat kada je porudžbina preuzeta
 - može otkriti obrasce vezane za doba dana
- **is_weekend:** označava da li je dostava tokom vikenda
- **is_rush_hour:** označava period pojačanog saobraćaja
- **is_bad_weather:** označava nepovoljne vremenske uslove

Pretprocesiranje: priprema podataka za model

- Očišćeni podaci nisu uvek odmah spremni za algoritam.
- Algoritmi u scikit-learn-u očekuju podatke u obliku koji mogu matematički da obrade.
- Pretprocesiranje obuhvata:
 - razdvajanje ulaznih karakteristika i ciljne promenljive,
 - definisanje numeričkih i kategorijskih kolona,
 - popunjavanje nedostajućih vrednosti,
 - skaliranje numeričkih kolona,
 - kodiranje kategorijskih kolona.

Numeričke, nominalne i ordinalne karakteristike

- **Numeričke karakteristike** su već izražene brojevima: distance_km, + pickup_hour, vehicle_condition, multiple_deliveries.
- **Nominalne kategorije** nemaju prirodan redosled: type_of_vehicle, city, type_of_order, weather_conditions.
- **Ordinalne kategorije** imaju smislen redosled: na primer road_traffic_density: low < medium < high < jam
- Različiti tipovi kolona zahtevaju različite transformacije.

Imputacija, skaliranje i kodiranje

- **Imputacija** popunjava nedostajuće vrednosti.
 - Kod numeričkih kolona često se koristi medijana.
 - Medijana je otpornija na ekstremne vrednosti od proseka.
- **Skaliranje** dovodi numeričke kolone na uporedivu skalu.
 - Ovo je važno za modele osetljive na veličinu vrednosti.
- **One-hot encoding** pretvara nominalne kategorije u numerički oblik bez lažnog redosleda.
- **Ordinal encoding** koristi se za kategorije koje zaista imaju redosled.

ColumnTransformer i ML pipeline

- ColumnTransformer omogućava da različite kolone prođu kroz različite transformacije.
- Numeričke kolone mogu proći kroz imputaciju i skaliranje.
- Nominalne kategorije mogu proći kroz one-hot encoding.
- Ordinalne kategorije mogu proći kroz ordinal encoding.
- ML pipeline povezuje pretprocesiranje i model u jednu celinu.
- Kada se pipeline trenira, prvo se primenjuje preprocessing, a zatim se trenira model korišćenjem nekog regresionog algoritma.

Linearna regresija kao početni model

- Linearna regresija je jednostavan i brz regresioni algoritam.
- Koristi se kao dobra početna tačka, odnosno baseline.
- Prvi model ne mora odmah biti najbolji.
- Njegova uloga je da pokaže da kompletan tok radi: pripremljeni podaci -> preprocessing -> linear regression -> treniranje -> čuvanje modela -> prve predikcije.
- Kada imamo prvi model, možemo ga evaluirati i upoređivati sa drugim algoritmima.

Evaluacija regresionog modela

- Kod regresije model retko pogađa potpuno tačnu vrednost.
- Zato ne pitamo samo: „Da li je model pogodio?”
- Umesto toga pitamo: „Koliko je model pogrešio?”
- Poredimo:
 - y_{test} : stvarne vrednosti
 - y_{pred} : predviđene vrednosti
- Evaluacija se radi na test skupu koji model nije video tokom treniranja.

Metrike regresije i poređenje algoritama

- **MAE** pokazuje prosečnu apsolutnu grešku u originalnoj jedinici mere.
- **MSE** računa prosečnu kvadratnu grešku i jače kažnjava velike promašaje.
- **RMSE** je koren iz MSE i ponovo se tumači u originalnoj jedinici mere.
- **R²** pokazuje koliko model objašnjava varijacije u ciljnoj promenljivoj u odnosu na jednostavno predviđanje proseka.
- Jedan model nije dovoljan za zaključak.
- Fer poređenje zahteva: - isti trening skup - isti test skup - isti preprocessing - iste metrike.
- Zato se mogu uporediti Linear Regression, Decision Tree, Random Forest i Gradient Boosting.