

Model spreman za svet: Čuvanje i integracija

Petak, 03:20 PM – Google Colab chat, #ml-projekat-reviews-v.2

Alex: Da li možete da verujete – stigli smo do finiša! Najzad imamo model koji je spreman za to da ga „spakujemo” i pripremimo za pravu upotrebu, ne samo za testiranje u Colabu!

Marc: Znači, vreme je da naš model postane deo pravih procesa?

Joakim: Samo neka se više ne izgubi nijedan final_final_MODEL.ipynb! Dosta je bilo fajlova po folderima – sad sve ide na GitHub i kao pravi .pkl fajl!

Da, došli smo do trenutka kada model prestaje da bude samo eksperiment – sada ga čuvamo, delimo i integrišemo kao pravi proizvod spreman za upotrebu u svakodnevnom poslovnim procesima. Ovaj korak je ono što izdvaja hobi projekte od ozbiljnih data science rešenja.

Kakvu tajnu otkrivamo ovde?

- Pokazaćemo kako da finalni model sačuvash u fajl (.pkl) koristeći joblib.
- Naučićemo kako da ponovo učitamo model i koristimo ga bez ponovnog treniranja – bilo za nove podatke, za integraciju u aplikaciju ili za demonstraciju timu ili menadžmentu.
- Finalizujemo rad na GitHub repozitorijumu – pravimo kompletan paket svog projekta, spreman za deljenje ili nastavak rada.

Ako se sećaš mini-projekata u Colabu ili vežbi sa GitHubom iz ranijih modula – ovo je nivo više. Sada postavljamo temelj za buduće data science projekte i učimo kako se znanje iz laboratorije seli u realan svet.

Zato, ovaj korak nije samo tehnički – on je naša karta za svet profesionalnog data sciencea. Kada jednom sačuvamo i podelimo model, naš rad više nije samo naš eksperiment – on postaje alat koji može da pravi razliku u stvarnom svetu, da olakša posao celom timu ili kompaniji i da pokaže naše veštine gde god želimo.

Spremi se da tvoj model zaista progovori i postane deo nečeg većeg!

Finalni model: Treniramo, čuvamo, spremamo za pravu upotrebu

04:08 PM – Google Colab chat, #ml-projekat-reviews-v.2

Alex: OK, ekipo, finale je pred nama! Ko bi rekao da ćemo jednog dana trenirati model na celoj bazi od 150.000+ recenzija, i to tako organizovano?

Marc: Ha! Kad se setim prvih testova u Colabu... Sad idemo na profi način, model ide u fajl, nema više „gubim kod, šalji mi notebook” fazona!

Joakim: Ajde, samo nemoj opet da zaboraviš da folder model/ treba da postoji – prošli put sam pola sata tražio gde se model izgubio!

Alex: Sve pišem, sve komitujem! Idemo korak po korak, evo ti ček-liste za naše finale!

Zašto radimo ovo baš ovako?

Do sada smo trenirali i upoređivali više modela koristeći Google Colab i podelu podataka na trening i test deo. Sada, kad znamo koji model vlada, vreme je da ga naučimo na svim podacima i sačuvamo ga za pravu upotrebu.

- Treniramo model na celokupnom skupu podataka (više nema skrivenih testova).
- Spakujemo pipeline (ceo tok od sirovih podataka do predikcije) u .pkl fajl koristeći joblib.
- Taj fajl možemo teleportovati bilo gde – lokalno, u cloud, na server... i on će uvek raditi identično!

Koraci za finale:

1. učitamo sve podatke i pročistimo ih (kao što smo vežbali ranije);
2. brišemo nepotrebne kolone, dodajemo review_length;
3. definišemo X i y (karakteristike i ciljnu promenljivu);
4. kreiramo pipeline sa svim potrebnim transformacijama i odabranim modelom (npr. RandomForest);

5. treniramo model na celom skupu;
6. sačuvamo model pomoću jobliba;
7. ne zaboravimo da dodamo model/ folder u svoj repozitorijum!

Evo kako će izgledati kompletan skript za treniranje modela sa različitim elementima koje smo napisali u prethodnim lekcijama:

```
1 import pandas as pd
2 from sklearn.feature_extraction.text import TfidfVectorizer
3 from sklearn.preprocessing import MinMaxScaler
4 from sklearn.compose import ColumnTransformer
5 from sklearn.pipeline import Pipeline
6 from sklearn.ensemble import RandomForestClassifier
7 import joblib
8
9 df = pd.read_csv("data/product_reviews_full.csv")
10
11 # drop all rows with missing values
12 df = df.dropna()
13
14 # Convert all sentiment values to lowercase and strip extra spaces
15 df['sentiment'] = df['sentiment'].astype(str).str.lower().str.strip()
16
17 # Convert column type to 'category'
18 df['sentiment'] = df['sentiment'].astype('category')
19
20
21 # Drop columns that are not useful for modeling
22 df = df.drop(columns=['review_uuid', 'product_name', 'product_price'])
23
24 # Create new column with length of each review_text
25 df['review_length'] = df['review_text'].astype(str).str.len()
26
27 # Define features and label
28 X = df[["review_title", "review_text", "review_length"]]
29 y = df["sentiment"]
30
31 # Define preprocessing
32 preprocessor = ColumnTransformer(
33     transformers=[
34         ("title", TfidfVectorizer(), "review_title"),
35         ("text", TfidfVectorizer(), "review_text"),
36         ("length", MinMaxScaler(), ["review_length"])
37     ]
38 )
39
40 # Define pipeline with the best model (e.g. RandomForestClassifier)
41 pipeline = Pipeline([
42     ("preprocessing", preprocessor),
43     ("classifier", RandomForestClassifier())
44 ])
45
46 # Train the model on the entire dataset
47 pipeline.fit(X, y)
48
49 # Save the model to a file
50 joblib.dump(pipeline, "model/sentiment_model.pkl")
51
52 print(" Model trained and saved as 'model/sentiment_model.pkl'")
```

Šta smo novo uradili u ovom koraku?

1. Model se fizički čuva u fajl.
Koristimo biblioteku joblib da model sačuvamo u fajl sentiment_model.pkl. Ovaj fajl:
 - sadrži ceo tok obrade i trenirani model;
 - može da se učita bilo kada i bilo gde bez ponovnog treniranja.
2. Koristimo ceo skup podataka za treniranje.
U ovoj fazi više ne delimo podatke na trening i test, već koristimo celokupni skup. Razlog je jednostavan: znamo da je ovaj model najbolji, pa želimo da on iskoristi sve dostupne podatke da nauči najviše što može.

Pogledajmo zajedno kako se trenira finalni model za analizu sentimenta:

<https://www.youtube.com/watch?v=qKxUxroY2lo>

Video: Treniranje finalnog modela i njegovo čuvanje u fajl
Autor: ITAcademy

Mini-aktivnost: Testiraj svoj model kao profesionalac!

Nakon što sačuvaš model u fajl, pokušaj da ga učitáš u novoj Colab svesci i napraviš bar jednu predikciju na novom tekstu recenzije (možeš izmisliti primer). Ovaj mali test simulira kako će tvoj model raditi kad ga zaista ubaciš u pravu aplikaciju.

Model spreman za akciju: Kako koristiti i testirati svoj model iz fajla

05:19 PM – Google Colab chat, #ml-projekat-reviews-v.2

Alex: Ljudi, stigli smo do dela koji najviše volim – model radi, fajl je sačuvan, sad možemo bukvalno bilo kada i bilo gde da „izbacimo” predikciju!

Marc: Čekaj, znači mogu da ga testiram na recenzijama koje sam juče skinuo s neta?

Joakim: Ili – još bolje – da napišem svoju recenziju („Kafa u menzi je užas!”) i proverim da li model stvarno pogađa ton...

Alex: Upravo tako! Daj da pokažemo kako se sve to radi uživo.

Nakon što smo uspešno trenirali i sačuvali svoj model, vreme je da ga oživimo – da ga učitamo iz .pkl fajla i isprobamo na potpuno novim primerima, bez dodatnog treniranja.

Ovaj pristup je pravi game changer za profesionalni rad:

- model koristimo u realnom okruženju;
- testiramo ga na novim podacima;
- spreman je za dalje deljenje, objavu na GitHubu ili integraciju u bilo koji softver.

Koraci za učitavanje i korišćenje modela

1. Uvezi biblioteke (joblib, pandas).
2. Učitaj prethodno sačuvani model:
`model = joblib.load("model/sentiment_model.pkl")`
3. Interaktivno unesi naslov i tekst recenzije.
4. Izračunaj dužinu teksta i upakuj sve u DataFrame.
5. Pozovi model za predikciju.
6. Prikaži rezultat korisniku.

Evo skripta koji će da obavi taj posao:

```
1 import joblib
2 import pandas as pd
3
4 # Load the saved model
5 model = joblib.load("model/sentiment_model.pkl")
6
7 print("Model loaded successfully!")
8 print("Type 'exit' at any point to stop.\n")
9
10 while True:
11     title = input(" Enter review title: ")
12     if title.lower() == "exit":
13         print("Exiting...")
14         break
15
16     text = input(" Enter review text: ")
17     if text.lower() == "exit":
18         print("Exiting...")
19         break
20
21     # Compute review length
22     review_length = len(text)
23
24     # Create a DataFrame from input
25     user_input = pd.DataFrame([
26         "review_title": title,
27         "review_text": text,
28         "review_length": review_length
29     ])
30
31     # Predict sentiment
32     prediction = model.predict(user_input)[0]
33     print(f" Predicted sentiment: {prediction}\n" + "-" * 40)
34
```

Setite se kako je izgledalo na početku – u prvim lekcijama, svaki put kada ste želeli da testirate nešto novo, morali ste iznova da trenirate modele u Jupyteru ili Colabu, da čekate rezultate i ručno unosite podatke. Bilo je to korisno za učenje, ali i prilično sporo i pomalo zamorno.

Sada, stvari su potpuno drugačije:

Sada radite kao pravi profesionalci! Vaš model je spreman za proizvodnju – jednom treniran, sačuvan u fajlu i spreman za korišćenje kad god i gde god zatreba. Sve što je nekada bio dug proces, sada se svodi na jednu liniju koda: učitaj model i koristi ga odmah! Ovakav pristup štedi vreme i resurse i otvara vrata za korišćenje modela u realnim aplikacijama – od web servisa, preko chatbotova, do automatizovanih analitičkih alata.

Šta se dešava u ovom kodu?

- Uvoze se potrebne biblioteke (joblib, pandas) – priprema za rad sa sačuvanim modelom.
- Učitava se prethodno trenirani model iz .pkl fajla: nema više ponovnog treniranja, samo load & predict.
- Korisniku se prikazuju poruka dobrodošlice i uputstvo kako da izađe iz aplikacije.
- Pokreće se beskonačna while petlja za interaktivni unos – korisnik može da testira model koliko god puta želi.
- Unose se naslov i tekst recenzije – kao da korisnik sam piše recenziju na sajtu.
- Moguće je prekinuti unos bilo kad (upisivanjem exit).
- Računa se dužina recenzije (broj karaktera), jer je to važan feature.
- Omogućava se prekid i u ovom koraku unosom exit.
- Računa se dužina recenzije (broj karaktera u tekstu).
- Formira se DataFrame sa ulaznim vrednostima.
- Model automatski transformiše podatke (vektoriše tekst, skalira brojeve itd.) i donosi predikciju sentimenta – potpuno transparentno za korisnika.
- Prikazuje se predikcija (positive, negative, neutral) i ciklus se ponavlja.
- Nema više ručnog fitovanja, nema čekanja – jednom treniran model radi trenutno, kad god zatreba.

Iz ovog koda vidimo koliko je jednostavno koristiti prethodno trenirani model koji smo sačuvali unutar fajla. Neophodno je samo da pripremimo ulazne podatke koje model koristi za svoje funkcionisanje:

- naslov recenzije;
- tekst recenzije;
- dužina recenzije.

Sve nakon toga, sačuvani model automatski obavlja za nas – od transformacije podataka (npr. vektorizacija teksta, skaliranje brojeva) do donošenja predikcije sentimenta.

Ovakav pristup omogućava da jednom trenirani model koristimo mnogo puta, bez potrebe za ponovnim treniranjem ili komplikovanim ručnim koracima. To čini ceo proces brzim, skalabilnim i spremnim za integraciju u stvarne aplikacije – bilo kao deo web servisa, chatbota ili desktop alata.

Pogledajmo zajedno proces interaktivnog testiranja prethodno treniranog modela:

<https://www.youtube.com/watch?v=m8RU4Xsz27Q>

Video: Testiranje prethodno treniranog modela
Autor: ITAcademy

Mini aktivnost: Tvoj model, tvoja recenzija

Probaj da uneseš nekoliko različitih recenzija (naslov + tekst) kroz interaktivnu petlju i posmatraj kako model reaguje na pozitivne, negativne i neutralne tonove.

- Šta se dešava ako napišeš recenziju koja je ironična ili dvosmislena?
- Da li model pogađa tvoj ton glasa i kod kraćih/dužih recenzija?

Zašto ova aktivnost?

Ovo je odličan način da testiraš robustnost svog modela i razumeš njegove granice – baš kao što to rade profesionalni ML inženjeri pre nego što model puste u svet.

Zadatak za vas: Prvi deployment mindset

Pokušajte da svoj kod pakovanja modela pretočite u malu komandnu aplikaciju (CLI) ili ga postavite na svoj GitHub.

Pozovite kolege iz grupe da unesu svoje recenzije i testiraju vaš model! Tako dobijate dragoceni feedback i iskustvo timskog rada.

Na ovaj način:

- vežbate i tehničke i soft veštine;
- prvi put dobijate osećaj šta znači plasirati svoj model u stvarni svet;
- spremate se za sledeći nivo u karijeri – rad na produkcionim data science projektima.

Zaključak modula

U ovom, završnom modulu, prošli smo kroz ceo životni ciklus ML projekta – od nestrukturisanih sirovih podataka, preko timske saradnje i analize, pa sve do gotovog modela spremnog za realnu upotrebu i deljenje.

Kroz niz lekcija, obradili smo sve ključne faze svakog ozbiljnog ML projekta i sada znamo kako da:

- postavimo moderno razvojno okruženje (GitHub + Colab);
- detaljno analiziramo i očistimo podatke;
- pravilno izaberemo i inženjeringujemo karakteristike;
- treniramo i uporedimo više modela, pa odaberemo najbolji;
- sačuvamo model i spremimo ga za praktičnu upotrebu.

Pored tehničkih veština, stekli smo uvid u najbolje prakse organizacije ML projekata, važnost modularnosti koda, reproduktivnosti rezultata i korišćenja alata kao što su Git i Colab u svakodnevnom radu.

Najvažnija poruka: Mašinsko učenje nije samo treniranje modela – već kompletan proces.

Razumevanje i pravilno sprovođenje svakog koraka vodi ka pouzdanijim, efikasnijim i održivim rešenjima u realnom svetu.

Ukoliko smo uspešno prošli kroz sve faze ovog modula, spremni smo da samostalno vodimo slične projekte i proširimo svoje znanje ka kompleksnijim zadacima, većim skupovima podataka i naprednijim modelima.

Takeaways

- ML projekat nije samo kod – to je proces koji traži plan, tim i disciplinu.
- Kvalitet podataka i priprema su važniji od samog modela.
- Svaki korak je važan – reproducibilnost i dobra dokumentacija čine razliku između amatera i profesionalaca.
- Tvoj sledeći izazov može biti još veći – imaš osnove da ga rešiš!

Seti se da su i Alex, Marc i Joakim počeli od nule, a sada zajedno izvode prave ML projekte. Sada je na tebe red!

Ovaj modul ti daje pravu ulaznicu za sledeći nivo: samostalne projekte, rad na otvorenim podacima ili timsku saradnju u realnim data science zadacima.

Pogledajmo, za kraj, video u kome ćemo ceo ovaj projekat sumirati dodavanjem README.md fajla unutar našeg GitHub repozitorijuma:

<https://www.youtube.com/watch?v=k2ArdhWevaM>

Video: Umesto zaključka – formulisanje README.md fajla GitHub repozitorijuma

Autor: ITAcademy

Sledeći korak: Tvoj prvi pametni asistent za klasifikaciju proizvoda

Stigli smo do momenta kada ne samo što možeš da analiziraš sentiment, već možeš da napraviš model koji automatski pomaže korisnicima – baš kao pravi asistent na online platformi!

U narednoj lekciji čeka te izazov: izgradićeš ML model koji na osnovu naslova proizvoda predlaže odgovarajuću kategoriju – brzo, precizno i potpuno automatizovano.

Kreiraj svoj prvi model za predikciju kategorija, upakuj ga u funkcionalan skript i ostavi trag na GitHubu kao pravi data science profesionalac!

Prava prilika da sve do sada naučeno pokažeš u projektu koji ima direktnu primenu i može pomoći hiljadama korisnika.

Spremni? Novi task, novi veliki korak!