

Operacija Čisti podaci: Temelj uspešnog ML modela

Ponedjeljak, 9:17 AM – Google Colab chat, #ml-projekat-reviews-v.2

Alex: Ljudi, nakon one šetnje kroz podatke, mislim da je vreme za ozbiljno sređivanje! Da li je neko video koliko „rupa” imamo u koloni sentiment?

Marc: I koliko raznih „cena” zapravo nije cena... Imam osećaj da ćemo danas više čistiti nego kodirati!

Joakim: Samo da ovog puta sve parsiramo kako treba – prošli put mi je „Free” kao broj zamalo uništilo model.

Alex: Idemo, drugari – ako sad napravimo dobar temelj, kasnije će sve ići lakše!

Nakon što smo u prethodnoj lekciji detaljno analizirali podatke i uočili glavne probleme (nedostajuće vrednosti, nekonzistentne oznake, čudne cene...), sada krećemo u jednu od najvažnijih faza svakog ML projekta: čišćenje i pretprocesiranje podataka.

Zašto je ovo ključno?

Ako model uči iz neurednih, netačnih ili nepreciznih podataka, ni rezultati neće biti bolji. Seti se iz prethodnih kurseva – dobro očišćeni podaci su pola uspeha u svakom ozbiljnom projektu!

Plan je da u ovoj lekciji:

- uklonimo nedostajuće vrednosti;
- standardizujemo oznake u koloni sentiment;
- parsiramo kolonu product_price i pretvorimo je u numerički tip;
- postavimo odgovarajuće tipove podataka za sve kolone.

Cilj je da do kraja ove lekcije naš skup podataka bude:

- čist (bez praznih i pogrešnih vrednosti);
- konzistentan (isti format vrednosti u svim kolonama);
- spreman za pravu analizu i treniranje modela.

P.S. Ovo je momenat kada iz vežbaonice prelazimo u profesionalnu kuhinju mašinskog učenja – svaki dobar model počinje čistim i kvalitetnim podacima!

Brisanje praznina: Dataset spreman za dalje

9:38 AM – Google Colab chat, #ml-projekat-reviews-v.2

Marc: OK, ljudi, vreme je da sredimo „rupe” u podacima. Koliko redova gubimo ako obrišemo sve sa NaN vrednostima?

Joakim: Evo gledam... I nije tako strašno – ostaje nam još uvek više nego dovoljno recenzija za treniranje.

Marc: Dobar deal, samo pazimo da ne obrišemo nešto što nam je baš bitno! (Sećam se kad sam izbrisao pola tabele sa korisničkim podacima u prošlom projektu... Nikad više!)

Alex: Dogovoreno! Hajde da odradimo dropna(), ali prvo da proverimo efekte. Ako ostane dovoljno podataka – nastavljamo dalje. Ako gubimo previše – razmotrićemo popunjavanje vrednosti.

U prethodnoj lekciji smo analizirali gde se nalaze nedostajuće vrednosti u našem skupu podataka. Sada prelazimo na praktičan korak – uklanjamo sve redove koji sadrže NaN vrednosti, kako bismo dataset učinili zdravim za naredne faze analize i modelovanja.

Zašto je ovo važno?

- Nedostajuće vrednosti mogu zbuniti model, izazvati greške ili maskirati prave obrasce.
- Čist skup podataka → lakše i sigurnije dalje analize.

Tip

U velikim projektima nije uvek idealno brisati sve sa NaN vrednostima – nekad je bolje popuniti (inputovati) vrednosti ili analizirati uzrok praznina. Ovde, zbog veličine i strukture skupa, brisanje je bezbedna i brza opcija.

Evo koda kojim ćemo ukloniti sve redove sa nedostajućim vrednostima i proveriti efekat takve operacije:

```
1 # Drop all rows with missing values
2 df = df.dropna()
3
4 # Display new shape of the dataset
5 print("New dataset shape:", df.shape)
6
7 # Count missing values per column
8 print("Missing values per column:")
9 print(df.isna().sum())
```

Pogledajmo zajedno kako se obrađuju nedostajuće vrednosti u našem ML projektu:

<https://www.youtube.com/watch?v=6wf95mVEBEY>

Video: Obrada nedostajućih vrednosti
Autor: ITAcademy

Mini-aktivnost: Koliko podataka smo izgubili?

Pre nego što zauvek izbrišeš redove sa nedostajućim vrednostima, izračunaj:

1. Koliko ukupno redova ima dataset pre uklanjanja?
2. Koliko redova ima posle dropna()?
3. Koliko je to procentualno (koliko % podataka je izgubljeno)?
4. Bonus: Pogledaj nasumično nekoliko redova koji će biti obrisani. Da li ima nešto zanimljivo među njima? Da li možda želiš neke od tih podataka ipak da zadržiš ili popuniš?

Razmisli:

- Da li je dataset i dalje dovoljno velik za analizu?
- Da li je brisanje najjednostavnija i najpametnija opcija za naš slučaj?

Pogledajmo rešenje.

```

1  import pandas as pd
2
3
4  # load dataset from GitHub
5  url = "https://raw.githubusercontent.com/vladimir-drezevic/ml-product-reviews-project/main/data/product_reviews_full.csv"
6
7
8  df = pd.read_csv(url)
9
10 # Count the number of rows before removing missing values
11 rows_before = len(df)
12
13 # Filter out rows that contain at least one missing value
14 rows_with_nan = df[df.isnull().any(axis=1)]
15
16 # Display a random sample of rows that will be removed
17 print(" Randomly selected rows containing missing values:\n")
18 print(rows_with_nan.sample(n=min(5, len(rows_with_nan)), random_state=42))
19
20 # Remove rows with any missing values
21 df_cleaned = df.dropna()
22
23 # Count the number of rows after removing missing values
24 rows_after = len(df_cleaned)
25
26 # Show removal statistics
27 print("\n Removal statistics:")
28 print(f"- Number of rows before: {rows_before}")
29 print(f"- Number of rows after: {rows_after}")
30 print(f"- Number of removed rows: {rows_before - rows_after}")
31

```

Standardizacija kolone sa cenom: Parsiranje product_price

12:10 PM – Google Colab

Alex: Ekipooooo, imamo jednu klasičnu data zbrku! Kolona product_price nam je puna svega i svačega: brojevi, dolar znaci, razmaci, pa i tekst tipa „Not Available”... Kako ćemo ovo srediti?

Marc: Ovo me podseća na onaj kaos sa podacima u našem prvom Python projektu... Sećaš se, sve što nije broj – smeta modelu! Idemo sistematski – čistimo, parsiramo, pa pretvaramo u float.

U prethodnoj fazi, pomoću EDA, kao početni korak utvrdili smo da kolona product_price sadrži mešavinu:

- čistih numeričkih vrednosti (npr. 48.18) i
- tekstualnih zapisa sa valutnim prefiksom za američki dolar npr. \$48.18, \$13190.

Ova neujednačenost onemogućava direktnu analizu, jer vrednosti nisu konzistentnog formata. Zbog toga su vrednosti interpretirane korišćenjem tipa object, a ne upotrebom nekog specijalizovanog numeričkog tipa.

Sada ćemo:

- ukloniti oznaku za valutu iz tekstualnih vrednosti;
- očistiti eventualne dodatne razmake;
- konvertovati sve vrednosti u numerički tip (float) i
- proveriti rezultate.

Na kraju, imaćemo kolonu sa brojevima koje možemo dalje analizirati kako bismo utvrdili da li ćemo takve podatke koristiti prilikom treniranja modela.

Koraci koje prolazimo zajedno

1. Pretvaramo vrednosti u tekst i čistimo ih.

Uklanjanje dolar znak, nepotrebne karaktere i razmake:

```
1 # Step 1: Convert to string and remove the 'USD' prefix and any leading/trailing spaces
2 df['product_price_cleaned'] = (
3     df['product_price']
4     .astype(str)
5     .str.replace(r'$', '', regex=True) # Remove '$'
6     .str.replace(r'[^\d.]', '', regex=True) # Remove all non-numeric characters except the dot
7     .str.strip()
8 )
```

2. Pretvaramo očišćeni tekst u numerički tip (float).

```
1 # Step 2: Convert cleaned string to float
2 df['product_price'] = pd.to_numeric(df['product_price_cleaned'], errors='coerce')
```

3. Brišemo privremenu kolonu.

```
1 # Step 3: Drop the temporary column
2 df = df.drop(columns=['product_price_cleaned'])
```

4. Uklanjanje redova gde je cena i dalje NaN (neuspešna konverzija).

```
1 # Step 4: Drop any rows where conversion failed (still NaN)
2 df = df.dropna(subset=['product_price'])
```

5. Proveravamo rezultat.

```
1 # Step 5: Confirm result
2 print("Column type after parsing:", df['product_price'].dtype)
3 print("\nPrice summary:")
4 print(df['product_price'].describe())
```

Šta zapravo radimo?

- Svi podaci se pretvaraju u stringove kako bismo mogli da ih obradimo tekstualno.
- Brišemo oznaku valute za američki dolar ako postoji (npr. \$48.18 →18).
- Uklanjanje razmake, simbole i sve ostalo što nije broj ili tačka (npr. 1,199.99 →99).
- Uklanjanje prazne karaktere sa početka i kraja.
- Konvertujemo prečišćeni tekst u numerički format (float); vrednosti koje ne mogu da se konvertuju postaju NaN.
- Uklanjanje redova sa NaN vrednostima u koloni product_price i tako brišemo nevažeće cene koje nisu mogle da se parsiraju (ukoliko ih ima).
- Prikazujemo osnovne statistike (min, max, prosek itd.) za proveru uspešnosti konverzije.

Pogledajmo zajedno kako se sprovode svi ovi koraci zarad dobijanja kolone sa cenama koje možemo da upotrebimo za dalju analizu:

<https://www.youtube.com/watch?v=kf7ErSL7Brl>

Video: Parsiranje vrednosti iz kolone product_price
Autor: ITAcademy

Mini-aktivnost: Standardizacija vrednosti u koloni sentiment

U prethodnoj lekciji, prilikom istraživačke analize podataka, otkrili smo da se vrednosti u koloni sentiment pojavljuju u različitim oblicima, kao što su:

- Positive i positive;
- Negative i negative;
- Neutral i neutral.

Ako ostavimo ovakve zapise, model će ih tretirati kao različite klase, što će uneti greške u treniranje i evaluaciju. Zadatak je da očistimo i ujednačimo sve vrednosti u ovoj koloni, tako da na kraju dobijemo samo tri stvarno jedinstvene vrednosti: positive, negative i neutral.

Stoga, tvoj zadatak je sledeći:

- obezbedi da sve vrednosti u koloni sentiment budu zapisane na standardizovan način: malim slovima (positive, negative, neutral), bez duplikata zbog razlika u veličini slova ili formatu zapisa;
- Nakon standardizacije vrednosti, osiguraj da kolona sentiment ima category tip podatka.

Hint: Ovu mini-aktivnost je moguće obaviti sprovođenjem nekoliko jednostavnih koraka:

1. pretvori sve vrednosti u koloni sentiment u mala slova;
2. proveri koje vrednosti su sada prisutne u koloni;
3. proveri da li ima nepoznatih ili nepripadajućih vrednosti (npr. none, ?, NaN itd.);
4. očisti te vrednosti tako da ostanu samo positive, negative i neutral;
5. konvertuj tip podatka u category.

Pogledajmo rešenje.

```
1 # Step 1: Convert all sentiment values to lowercase and strip extra spaces
2 df['sentiment'] = df['sentiment'].astype(str).str.lower().str.strip()
3
4 # Step 2: Show all unique values in the sentiment column
5 print("Unique sentiment values after cleaning:")
6 print(df['sentiment'].value_counts())
7
8 # Step 3: Convert column type to 'category'
9 df['sentiment'] = df['sentiment'].astype('category')
10 print("\nSentiment column converted to type:", df['sentiment'].dtype)
```

Ukoliko naiđeš na poteškoće u realizaciji, možeš pogledati kompletan video-vodič. Kao i do sada, mini-vodič pogledaj tek nakon što samostalno pokušaš da realizuješ zadatak.

<https://www.youtube.com/watch?v=h48vdMmzD2g>

Video: Standardizacija vrednosti iz kolone sentiment
Autor: ITAcademy

Zaključak lekcije

Svaki ozbiljan projekat u mašinskom učenju počinje sa podacima, ali dobar model nastaje samo iz dobro pripremljenih podataka. U ovoj lekciji napravili smo ključan iskorak: prešli smo put od neuredne tabele do čistog, konzistentnog skupa spremnog za pravu analizu.

Šta smo postigli?

- Identifikovali i uklonili sve nedostajuće i nevažeće vrednosti.
- Standardizovali kolone i očistili format cena.
- Pripremili sve podatke tako da ih model može razumeti i koristiti bez skrivenih zamki.

Zašto je ovo važno?

- Prljavi podaci vode do loših modela, pogrešnih zaključaka i frustracije.
- Kvalitet pretprocesiranja direktno utiče na tačnost i stabilnost svakog ML rešenja.
- Veštine koje ste sada usvojili koristićete u svakom ozbiljnom data science projektu, bez izuzetka!

Takeaways

- Garbage in, garbage out – Dobro pretprocesirani podaci su pola posla!
- Standardizacija i čišćenje su temelji svakog narednog koraka u ML-u.
- Veoma je važno dokumentovati sve što radimo sa podacima, zbog timske transparentnosti i mogućnosti kasnijih poboljšanja.

Zahvaljujući pažljivom čišćenju, sada smo spremni za sledeći nivo: inženjering karakteristika i izgradnju modela koji može dati realnu poslovnu vrednost.

Zato, kada sledeći put otvorite neuredan CSV fajl, setite se – svaki red koji očistite jeste korak bliže uspešnom ML projektu!

Sledeći korak: Inženjering karakteristika

Sa čistim i doslednim podacima pred sobom, vreme je za pravi kreativni deo svakog ML projekta – feature engineering! Sledeća lekcija nas vodi u otkrivanje i oblikovanje skrivenih dragulja među podacima: biramo koje informacije zaista vrede za naš model, transformišemo ih i kreiramo nove, još moćnije karakteristike.

Upravo ovde se pravi razlika između prosečnog i sjajnog modela. Spremni za fazu u kojoj vaše odluke najviše doprinose uspehu celog projekta? Idemo dalje – pravi izazovi tek dolaze!